作业三

左之睿 191300087 人工智能学院 人工智能学院选修 本科

1、第六章习题1

(a)设X的列秩为r，故X的列向量可以由一组基$\{c_1,...,c_r\}$表示，故$m*r$矩阵$C=[c_1,...,c_r]$可以使得X的每一个列向量都是C的所有列向量构成的一个线性组合，即存在$r*n$矩阵R使得$X=CR$，这也意味着X的每个行向量都是R的行向量的线性组合，即**X的行秩**$\leq$**R的行秩**，但是R一共只有r行，所以R的行秩$\leq r$，即**X的行秩**$\leq$**其列秩r**

类似的方法可以证明X的列秩$\leq$其行秩。

综上，行秩=列秩，因此$rank(X)=rank(X^T)$

(b)行秩必然$\leq$行数m
列秩必然$\leq$列数n
由(a)知，行秩=列秩，故$rank(A)\leq\min\{m,n\}$

(c)设$rank(X)=a,rank(Y)=b$，由于行秩=列秩，故考察行向量。
设X行向量的极大线性无关向量组为$\{x_1,...,x_a\}$
Y行向量的极大线性无关向量组为$\{y_1,...,y_b\}$
对于$X+Y$而言，其行向量一定属于$span\{x_1,...,x_a,y_1,...,y_b\}$，即
$rank(X+Y)\leq rank(X)+rank(Y)$

(d)记$A=XY$，则A的每个行向量都是Y的行向量的线性组合，故A的行秩$\leq$Y的行秩(即Y的秩)
类似的，A的每个列向量都是X的列向量的线性组合，故A的列秩$\leq$X的列秩(即X的秩)

综上，$rank(A)\leq rank(X)\ and\ rank(A)\leq rank(Y)$
$\Rightarrow rank(A)\leq\min\{rank(X),rank(Y)\}$

(e)证明两个性质：
1、A列满秩时，则$rank(AB)=rank(B)$
2、A行满秩时，则$rank(BA)=rank(B)$

证明性质1如下：
当A列满秩时，将其行最简形矩阵写成分块矩阵形式$A_0=\begin{pmatrix}E_n\\0\end{pmatrix}_{m*n}$
0代表零矩阵，此外还存在可逆方阵P(可逆所以满秩)使$PA=PA_0$
故$PAB=\begin{pmatrix}E_n\\0\end{pmatrix}B=\begin{pmatrix}B\\0\end{pmatrix}$
由于满秩方阵P可看成有限个初等方阵之之积，故与P相乘实际上相当于做初等变换
故$rank(AB)=rank(PAB)=rank(B)$
性质2证明同理，不再赘述

当$m\geq n$时，X列满秩，X^T行满秩
由性质1，$rank(XX^T)=rank(X^T)=rank(X)$
由性质2，$rank(X^TX)=rank(X)$
故$rank(X)=rank(XX^T)=rank(X^TX)$
$m<n$时同理，不再赘述

(f)当x是零向量时，xx^T的秩=0；x非零向量时，xx^T的秩为1

证明题解答如下：对于实对称矩阵X，存在正交矩阵Q满足$X=Q^{-1}\Lambda Q$，其中$\Lambda=diag(\lambda_1,...,\lambda_r)$，$\lambda_i$是X的特征值

由于正交矩阵满秩，故X的秩=Λ的秩=X的非零特征值的个数

2、第六章习题4

(a)直接对等式右边做矩阵乘法即可证明两边相等。

(b)结果为$(v_1,\ldots,v_k,0,\ldots,0)^T$(从第k个元素之后全是0)

(c)第k轮循环会将A的第k列中第k+1个及之后的元素全部变为0(如k=1时，$A^{(2)}$的第一列中第2到n个元素全为0)，运行完该算法后最终A会变成一个上三角矩阵

(d)
行列式=1证明：
M_k是下三角矩阵，故其行列式=其对角线元素乘积$\Rightarrow det(M_k)=1$

下三角矩阵证明：
对于两个下三角矩阵，其乘积仍然为下三角矩阵，故$L=M_{n-1}\ldots M_1$也是下三角矩阵
由矩阵乘积的性质，$det(L)=det(M_{k-1})\ldots det(M_1)=1$，证毕

(e)
存在性证明：
由算法流程，$A^{(n)}=LA$，而其中的$L=M_{n-1}\ldots M_1$，在(d)中已经证得L是一个对角线元素为1的下三角矩阵，故存在性得证。

唯一性证明：
不妨假设分解结果不唯一，即$A=L_1U_1=L_2U_2$，其中L_1,U_1,L_2,U_2均可逆(A奇异)，故$U_1U_2^{-1}=L_1^{-1}L_2$，U都是上三角矩阵，L都是下三角矩阵且对角线元素为1，这意味着若要满足等式，则$U_1U_2^{-1}=L_1^{-1}L_2=I\Rightarrow L_1=L_2,U_1=U_2$，唯一性得证

(f)首先，A有唯一的LU分解$A=LU$，又因为A的实对称正定矩阵，故U的对角线元素非0，即U也可以分解成$U=DP$，$D=diag(u_{11},\ldots,u_{nn})$，P是一个对角线元素为1的上三角矩阵，且在上三角中，第i行的1之后的元素为$(\frac{u_{i,i+1}}{u_{ii}},\ldots,\frac{u_{in}}{u_{ii}})$，此时$A=LDP$

$A^T=A\Rightarrow(LDP)^T=P^TDL^T(D\text{是对角阵})=LDP\Rightarrow P=L^T$，即$A=LDL^T$
因为LU分解是唯一的，相应的LDL分解同样具有唯一性。

(g)对于LDL分解$A=LDL^T$，若D对角线元素为正，则可令$G=LD^{\frac{1}{2}}$，此时得到$A=GG^T$

先说明D对角线元素为正：A正定$\rightarrow$A的各阶顺序主子式$>0\rightarrow$D的对角线元素为正，即可以令$D=D^{\frac{1}{2}}D^{\frac{1}{2}}$

再说明$G=LD^{\frac{1}{2}}$是对角线元素为正的下三角矩阵：由于L是对角线元素为1的下三角矩阵，D是对角线元素为正的对角阵，显然$G=LD^{\frac{1}{2}}$是对角线元素为正的下三角矩阵

最后是唯一性，由于LDL分解唯一，故$G=LD^{\frac{1}{2}}$唯一

综上，存在唯一的Cholesky分解

3、第七章习题1

(a)编译成功截图如下：

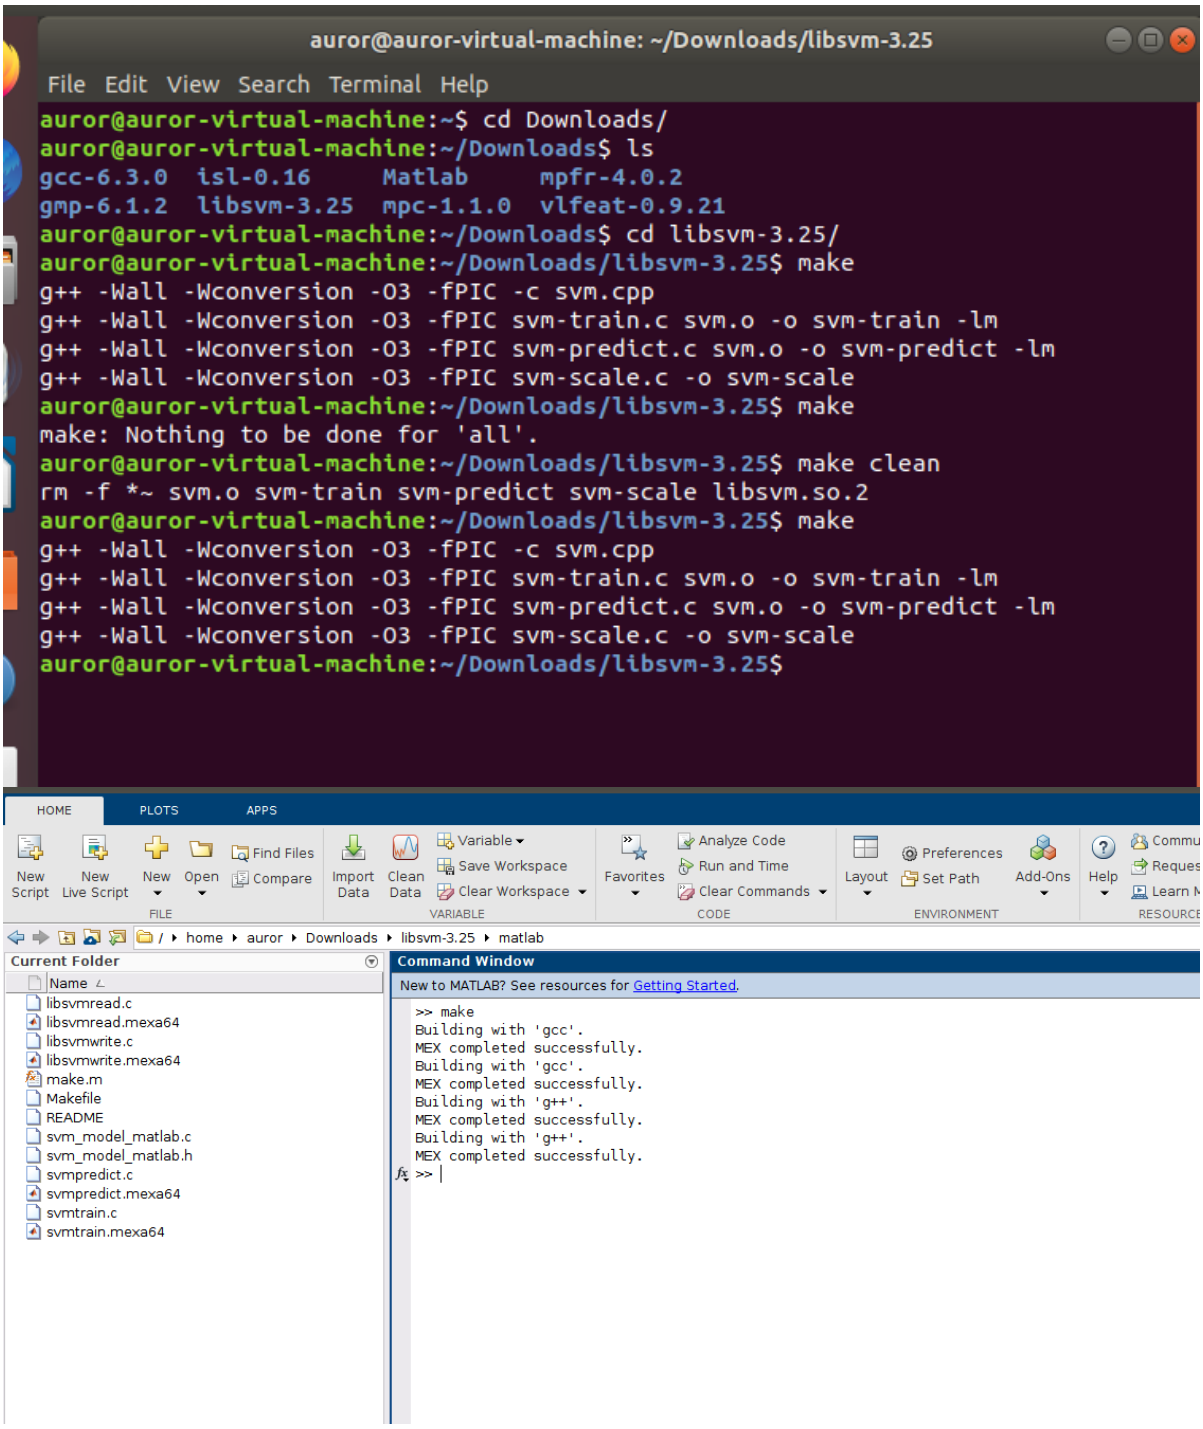

(b)

i. 结果如下，准确率为66.925%

```
D:\Study\Grade 3\Second\模式识别\HW3\libsvm-3.25\windows>svm-train svmguide1 model
.....*..*
optimization finished, #iter = 5371
nu = 0.606150
obj = -1061.528918, rho = -0.495266
nSV = 3053, nBSV = 722
Total nSV = 3053

D:\Study\Grade 3\Second\模式识别\HW3\libsvm-3.25\windows>svm-predict svmguide1.t model out
Accuracy = 66.925% (2677/4000) (classification)
```

ii. 结果如下，规范化之后准确率提升到96.15%

```
D:\Study\Grade 3\Second\模式识别\HW3\libsvm-3.25\windows>svm-scale -l -1 -u 1 -s range svmguide1 > train.txt

D:\Study\Grade 3\Second\模式识别\HW3\libsvm-3.25\windows>svm-scale -r range svmguide1.t > test.txt

D:\Study\Grade 3\Second\模式识别\HW3\libsvm-3.25\windows>svm-train train.txt model
*
optimization finished, #iter = 496
nu = 0.202599
obj = -507.307046, rho = 2.627039
nSV = 630, nBSV = 621
Total nSV = 630

D:\Study\Grade 3\Second\模式识别\HW3\libsvm-3.25\windows>svm-predict test.txt model out
Accuracy = 96.15% (3846/4000) (classification)
```

iii. 结果如下，准确率为95.675%

```
.....................................................................................
....*.......................................*
optimization finished, #iter = 3509115
nu = 0.121917
obj = -376.234540, rho = 5.887607
nSV = 381, nBSV = 375
Total nSV = 381

D:\Study\Grade 3\Second\模式识别\HW3\libsvm-3.25\windows>svm-predict svmguide1.t model out
Accuracy = 95.675% (3827/4000) (classification)
```

iv. 结果如下，准确率为70.475%

```
D:\Study\Grade 3\Second\模式识别\HW3\libsvm-3.25\windows>svm-train -c 1000 svmguide1 model
....*..*
optimization finished, #iter = 6383
nu = 0.000721
obj = -1114.038221, rho = -0.407723
nSV = 3001, nBSV = 0
Total nSV = 3001

D:\Study\Grade 3\Second\模式识别\HW3\libsvm-3.25\windows>svm-predict svmguide1.t model out
Accuracy = 70.475% (2819/4000) (classification)
```

v. 使用easy.py最终得到$C=2,\gamma=2$，使用此参数训练得到准确率是96.875%

从实验中不难发现，合适的超参数对模型性能的影响很大，除此之外，数据是否规范化也是提高模型性能的重要因素

(c)svmguide3就是一个不平衡数据集。
在默认参数下准确率很低，仅有2.43902%，如下图所示

```
D:\Study\Grade 3\Second\模式识别\HW3\libsvm-3.25\windows>svm-train svmguide3 model
*
optimization finished, #iter = 535
nu = 0.452614
obj = -545.901031, rho = -0.985060
nSV = 570, nBSV = 552
Total nSV = 570

D:\Study\Grade 3\Second\模式识别\HW3\libsvm-3.25\windows>svm-predict svmguide3.t model out
Accuracy = 2.43902% (1/41) (classification)
```

通过-wi参数给第1类赋予权重后，随着权重不断增大模型准确率也不断提升，当设置到6时测试集准确率甚至达到了100%

```
D:\Study\Grade 3\Second\模式识别\HW3\libsvm-3.25\windows>svm-train -w1 3 svmguide3 model
*
optimization finished, #iter = 870
obj = -1349.760244, rho = -3.240444
nSV = 967, nBSV = 952
Total nSV = 967

D:\Study\Grade 3\Second\模式识别\HW3\libsvm-3.25\windows>svm-predict svmguide3.t model out
Accuracy = 70.7317% (29/41) (classification)

D:\Study\Grade 3\Second\模式识别\HW3\libsvm-3.25\windows>svm-train -w1 6 svmguide3 model
.
WARNING: using -h 0 may be faster
*
optimization finished, #iter = 1098
obj = -1818.528607, rho = -3.560908
nSV = 1111, nBSV = 1096
Total nSV = 1111

D:\Study\Grade 3\Second\模式识别\HW3\libsvm-3.25\windows>svm-predict svmguide3.t model out
Accuracy = 100% (41/41) (classification)
```

4、第七章习题2

(a)欲证κ_{HI}是合法的核函数，即为证对非负向量样本集$\{\mathbf{x}_1,\ldots,\mathbf{x}_n\}$，核矩阵$K=(\kappa_{HI}(\mathbf{x}_i,\mathbf{x}_j))_{n*n}$是半正定的。

任取向量$\mathbf{a}\in R^n$，有

$$\begin{aligned}\mathbf{a}^TK\mathbf{a}&=\sum_{p=1}^{n}\sum_{q=1}^{n}a_pK_{ij}a_q\\&=\sum_{p=1}^{n}\sum_{q=1}^{n}a_pa_q\sum_{i=1}^{d}\kappa_{HI}(x_{pi},x_{qi})\\&=\sum_{p=1}^{n}\sum_{q=1}^{n}\sum_{i=1}^{d}a_pa_q\kappa_{HI}(x_{pi},x_{qi})\\&=\sum_{i=1}^{d}\mathbf{a}^TK_i'\mathbf{a}\end{aligned}$$

其中，K_i'是将样本x_i中各维度元素拿出来用κ_{HI}生成的核矩阵，$\mathbf{x_i}$是非负向量，故其个元素也是非负标量，又因为κ_{HI}对非负标量是合法的核函数，故K_i'半正定，$\mathbf{a}^TK_i'\mathbf{a}\geq 0$，因此，$K$也半正定，因此$\kappa_{HI}$对非负向量也是合法的核函数

(b)由于Y只是由于将$x_1,\ldots,x_n$重新排序获得，故X经过一系列初等变换可以变成Y，即$Y=P^TXP$，P是若干个初等矩阵之积，其可逆。

当X正定时，对任意$a\in R^n$，$a^TYa=a^TP^TXPa=(Pa)^TX(Pa)>0$(半正定加等号即可)

当Y正定时，对任意$a\in R^n$，$a^TXa=a^T(P^{-1})^TYP^{-1}a=(P^{-1}a)^TY(P^{-1}a)>0$(半正定加等号即可)
综上，当且仅当Y(半)正定时，X是(半)正定的

(c)由于$x_1,\ldots,x_n$已经按大小顺序排好，故核矩阵第i行的元素为$x_1,\ldots,x_i,x_i,\ldots,x_i$

对该矩阵做如下初等变换P：每一行减上一行，每一列减左一列
之后得到矩阵$A=diag(x_1,x_2-x_1,\ldots,x_n-x_{n-1})$，注意其对角线个元素均非负，且$A=P^TXP$，$P^T$就相当于LDL分解中的L。

因为A对角元素非负，故A是半正定的，在(b)中，$Y=P^TXT$半正定当且仅当X半正定，本小问中，$A=P^TXP$，故A半正定当且仅当X半正定。

由于A是半正定的，故X也是半正定的，证毕

(d)欲证$\sum\limits_{i=1}^{d}\min(x_i,y_i)\leq\sum\limits_{i=1}^{d}\frac{2x_iy_i}{x_i+y_i}$，只需证对任意两正标量$x,y$，有$\min(x,y)\leq\frac{2xy}{x+y}$即可。

当$\min(x,y)=x$时，$\frac{2xy}{x+y}-x=\frac{xy-x^2}{x+y}\geq 0\Rightarrow\frac{2xy}{x+y}\geq\min(x,y)$
$\min(x,y)=y$同理

综上，对任意两正标量x,y，有$\min(x,y)\leq\frac{2xy}{x+y}$，故$\sum\limits_{i=1}^{d}\min(x_i,y_i)\leq\sum\limits_{i=1}^{d}\frac{2x_iy_i}{x_i+y_i}$，即
$\kappa_{HI}(\mathbf{x},\mathbf{y})\leq\kappa_{\chi^2}(\mathbf{x},\mathbf{y})$

(e)
先证明是合法的核函数：取$\phi(x)=(\sqrt{x_1},\ldots,\sqrt{x_n})$，即有$\kappa_{HE}(x,y)=\phi^T(x)\phi(y)$，因此是合法的核函数

再证$\kappa_{HE}(x,y)\geq\kappa_{\chi^2}(x,y)$，同样只需要证明对任意两正标量$x,y$，有$\sqrt{xy}\geq\frac{2xy}{x+y}$即可。
基础不等式有$\frac{1}{x}+\frac{1}{y}\geq 2\sqrt{\frac{1}{xy}}\Rightarrow\sqrt{xy}\geq\frac{2}{1/x+1/y}=\frac{2xy}{x+y}$

故有$\kappa_{HE}(x,y)\geq\kappa_{\chi^2}(x,y)$

(f)设x的特征中，最大值为a，令$\phi: N^d \to \{0,1\}^{ad}$，$\phi(x) = (\phi_1(x_1), \ldots, \phi_d(x_d))$，其中$\phi_i(x_i) = (1, 1 \ldots, 1, 0, \ldots, 0)$，即用长度为a的01向量来表示x的每个特征，其中1的个数即为x_i对应的数值。

对于标量x,y，$\phi^T(x)\phi(y) = \min(x, y)$

对向量x,y，$\phi^T(x)\phi(y) = \sum\limits_{i=1}^{d} \min(x_i, y_i) = \kappa_{HI}(x, y)$

5、第九章习题2

(a) LLE的优化问题是：$\min E = \sum\limits_{i=1}^{n} e_i = \sum\limits_{i=1}^{n} W_i^T(\mathbf{x}_i - \mathbf{x}_j)(\mathbf{x}_i - \mathbf{x}_j)^T W_i$

其中，$W_i = (w_{i1}, \ldots, w_{ik})^T$是k个近邻样本权重

令$Z_j = (\mathbf{x}_i - \mathbf{x}_j)(\mathbf{x}_i - \mathbf{x}_j)^T$，$\mathbf{x}_j$是$\mathbf{x}_i$的k个近邻，故约束条件可以写成$W_i^T e = 1$，e是长度为k的全1向量

故Lagrange函数$L(W, \lambda) = \sum\limits_{i=1}^{n} W_i^T Z_i W_i + \lambda(W_i^T e - 1)$

对其求偏导等于0可以解得$W_i = \frac{Z_i^{-1} e}{e^T Z_i^{-1} e}$

(b)

i.将$\mathbf{x}_i = Q\mathbf{x}_i$代入$e_i$

$$
\begin{aligned}
e_i &= ||Q(\mathbf{x}_i - \sum_{j=1}^{n} w_{ij}\mathbf{x}_j)||^2 \\
&= [Q(\mathbf{x}_i - \sum_{j=1}^{n} w_{ij}\mathbf{x}_j)]^T [Q(\mathbf{x}_i - \sum_{j=1}^{n} w_{ij}\mathbf{x}_j)] \\
&= (\mathbf{x}_i - \sum_{j=1}^{n} w_{ij}\mathbf{x}_j)^T Q^T Q(\mathbf{x}_i - \sum_{j=1}^{n} w_{ij}\mathbf{x}_j) \\
&\text{由于} QQ^T = Q^T Q = I \\
&= (\mathbf{x}_i - \sum_{j=1}^{n} w_{ij}\mathbf{x}_j)^T (\mathbf{x}_i - \sum_{j=1}^{n} w_{ij}\mathbf{x}_j) \\
&= e_i
\end{aligned}
$$

即旋转时保持不变性

ii.将$\mathbf{x}_i = \mathbf{x}_i + t$代入$e_i$

$$
\begin{aligned}
e_i &= ||\mathbf{x}_i + t - \sum_{j=1}^{n} w_{ij}(\mathbf{x}_j + t)||^2 \\
&= ||\mathbf{x}_i + t - \sum_{j=1}^{n} w_{ij}\mathbf{x}_j - t\sum_{j=1}^{n} w_{ij}||^2 \\
&= ||\mathbf{x}_i - \sum_{j=1}^{n} w_{ij}\mathbf{x}_j||^2 \\
&= e_i
\end{aligned}
$$

即平移时保持不变性

iii.将$\mathbf{x}_i = s\mathbf{x}_i$代入$e_i$

$$
\begin{aligned}
e_i &= ||s\mathbf{x}_i - \sum_{j=1}^{n} w_{ij} s\mathbf{x}_j||^2 \\
&= s^2||\mathbf{x}_i - \sum_{j=1}^{n} w_{ij}\mathbf{x}_j||^2 \\
&= s^2 e_i
\end{aligned}
$$

本质上就是给目标函数乘了一个常数的系数，不影响后续求解，故缩放时保持不变性

(c)
原因：重构向量的权重w_{ij}是乘在了$\mathbf{x}_i$的近邻样本上，这反映了$\mathbf{x}_i$与其近邻样本$\mathbf{x}_j$之间的关系，因此通过这种方式求解$\mathbf{x}_i$的重构表示可以保留局部上的样本之间的关系，从而能够保持局部几何性质。

消去了哪些自由度：$\sum\limits_{i=1}^{n} y_i = 0$消去了平移自由度

$\sum\limits_{i=1}^{n} y_i y_i^T = I$消去了缩放自由度

仍存在的自由度是否有负面影响：仍存在旋转自由度，但从(b)的i可知不会产生负面影响

(d)$\sum\limits_{i=1}^{n} ||\mathbf{y}_i - \sum\limits_{j=1}^{n} w_{ij}\mathbf{y}_j||^2 = \sum\limits_{i=1}^{n} ||(1-w_{ii})\mathbf{y}_i + \sum\limits_{j=1,j\neq i}^{n} (-w_{ij})\mathbf{y}_j||^2$

其中，$(1-w_{ii})\mathbf{y}_i + \sum\limits_{j=1,j\neq i}^{n} (-w_{ij})\mathbf{y}_j = \sum\limits_{j=1}^{n} (I-W)\mathbf{y}_j$

$$
\begin{aligned}
&= \sum_{i=1}^{n} ||\sum_{j=1}^{n} (I-W)_{ij}\mathbf{y}_j||^2 \\
&= \sum_{i=1}^{n} [(\sum_{t=1}^{n} (I-W)_{it}\mathbf{y}_t)^T (\sum_{j=1}^{n} (I-W)_{ij}\mathbf{y}_j)] \\
\text{故优化目标函数} &= \sum_{t=1}^{n}\sum_{j=1}^{n}\sum_{i=1}^{n} [(I-W)_{it}^T (I-W)_{ij}\mathbf{y}_t^T\mathbf{y}_j] \\
&= \sum_{t=1}^{n}\sum_{j=1}^{n} M_{tj}\mathbf{y_t}^T\mathbf{y}_j \\
&= \sum_{i=1}^{n}\sum_{j=1}^{n} M_{ij}\mathbf{y}_i^T\mathbf{y}_j
\end{aligned}
$$

(e)
1)证明M半正定
$\forall \mathbf{x}, \mathbf{x}^T M\mathbf{x} = \mathbf{x}^T (I-W)^T (I-W)\mathbf{x} = ||(I-W)\mathbf{x}||^2 \geq 0$，故M半正定

2)证明$\mathbf{1}$是M的一个特征向量
$M = (I-W)^T(I-W) = I - W - W^T + W^T W$
$W^T W = (a_{ij})_{n*n} = (\sum\limits_{k=1}^{n} w_{ki}w_{kj})_{n*n}$
故
$M\mathbf{1} = \mathbf{1} - (\sum\limits_{i=1}^{n} w_{i1}, \ldots, \sum\limits_{i=1}^{n} w_{in})^T - (\sum\limits_{i=1}^{n} w_{1i}, \ldots, \sum\limits_{i=1}^{n} w_{ni})^T + (\sum\limits_{t=1}^{n}[\sum\limits_{k=1}^{n} w_{k1}w_{kt}], \ldots, \sum\limits_{t=1}^{n}[\sum\limits_{k=1}^{n} w_{kn}w_{kt}])^T$

注意：$\sum_{j=1}^{n} w_{ij} = 1$
因此有$M\mathbf{1} = -(\sum_{i=1}^{n} w_{i1}, \ldots, \sum_{i=1}^{n} w_{in})^T + (\sum_{t=1}^{n}[\sum_{k=1}^{n} w_{k1}w_{kt}], \ldots, \sum_{t=1}^{n}[\sum_{k=1}^{n} w_{kn}w_{kt}])^T$

$$= \sum_{t=1}^{n}[\sum_{k=1}^{n} w_{k1}w_{kt}] - \sum_{i=1}^{n} w_{i1}$$

$$= \sum_{t=1}^{n}[\sum_{i=1}^{n} w_{i1}w_{it}] - \sum_{i=1}^{n} w_{i1}$$

考虑上式中的第一个元素 $= \sum_{i=1}^{n} w_{i1} \sum_{t=1}^{n} w_{it} - \sum_{i=1}^{n} w_{i1}$

$$(\sum_{j=1}^{n} w_{ij} = 1)$$

$$= \sum_{i=1}^{n} w_{i1} - \sum_{i=1}^{n} w_{i1} = 0$$

对于其他位置的元素，同样可以得到为0，故$M\mathbf{1} = \mathbf{0}$
所以$\mathbf{1}$是特征值0对应的特征向量

再证明E_d满足两个约束条件

第一个：因为$\mathbf{1}$是特征向量，因为特征向量正交，故$\sum_{k=1}^{n} \xi_{ik} = 0, i = 2, 3, \ldots, d+1$，即$E_d$的每个行向量各元素之和为0，满足第一个约束。

第二个：$\mathbf{y}_i\mathbf{y}_i^T = (a_{mn})_{d*d} = (\xi_{m+1,i}\xi_{n+1,i})_{d*d}$

故$\sum_{i=1}^{n} \mathbf{y}_i\mathbf{y}_i^T$各个对角线元素为$\sum_{i=1}^{n} \xi_{ki}^2 = 1, k = 2, \ldots, d+1$

对于非对角线元素，有$\sum_{i=1}^{n} \xi_{m+1,i}\xi_{n+1,i} = 0$

综上，$\sum_{i=1}^{n} \mathbf{y}_i\mathbf{y}_i^T = I$，满足第二个约束

舍弃ξ_1的原因：舍弃后可以使$\mathbf{y}_i$均值为0，从而满足第一个约束

(f) 略